

Neural Machine Translation

Knowledge and Language Engineering Lab
이 원 기 (wklee@postech.ac.kr)


Goal

- 신경망 기계번역 모델에 대한 이해 및 구현
 - RNN 기반의 Sequence-to-Sequence 모델
 - Attention 메커니즘
- Torchtext
 - 효율적인 텍스트 데이터 (전) 처리를 위한 라이브러리

NEURAL MACHINE TRANSLATION

기계 번역

- 기계번역이란?
 - 원시문 (Source text) 를 다른 언어로 된 대상문장 (Target text) 로 자동 번역하는 기술



Google

자동 번역 기능이 있는 새 브라우저를 사용해 보세요. [Chrome 다운로드](#) [닫기](#)

번역

영어 한국어 독일어 언어 감지

한국어 영어 일본어

번역하기


KLE's research efforts are concentrated on three major areas. First is the core technology of Language processing, which is fundamental to the development of computer systems that recognize, understand, and generate the language. Machine Translation (MT) between Korean and other foreign Asian languages like Japanese, Chinese, and English is of our second concern. Our last concerned area is Information Retrieval (IR), especially related to web-based applications.

KLE의 연구 노력은 세 가지 주요 분야에 집중되어있다. 먼저, 인식 이해하고, 언어를 생성하는 컴퓨터 시스템의 개발에 필수적이다 언어 처리의 핵심 기술이다. 한국어, 일본어, 중국어, 영어와 같은 다른 외국의 아시아 언어 사이의 기계 번역 (MT)은 두 번째 문제입니다. 우리의 마지막 우려 지역, 특히 웹 기반 응용 프로그램과 관련된 정보 검색 (IR)입니다.

기존의 방법론

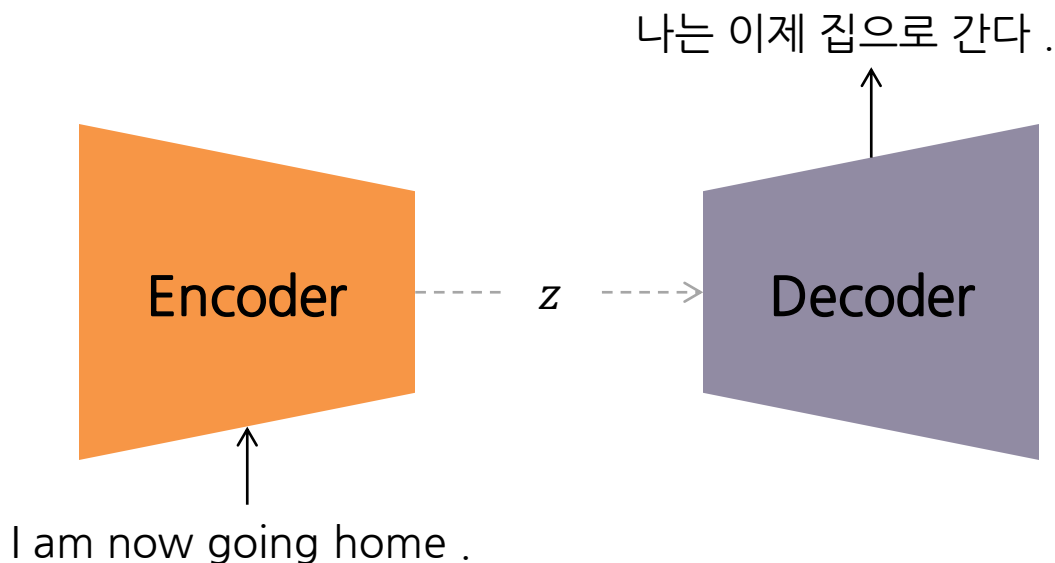
- 통계 기반 기계 번역 (Statistical Machine Translation: SMT)
 - 원시문과 대상문에 대한 확률식 정의
 - 원시문(ex. 영어) : $X = \{x_1, x_2, \dots, x_n\}$
 - 대상문(ex. 한국어): $Y = \{y_1, y_2, \dots, y_n\}$

$$\rightarrow P(Y|X) \cong P(X|Y) \cdot P(Y)$$



신경망 기반 기계번역

- Sequence-to-Sequence 모델
 - Encoder
 - : 무작위 길이의 Source 문장을 **고정된 길이의 Vector**로 변환
 - Decoder
 - : Encoder 의 Vector 정보와 입력(Input) 를 이용하여 **가변 길이의 문장 생성**



신경망 기반 기계번역

- 문제 정의

- $y_{1:n}^* = \operatorname{argmax} P(y_{1:n}|x_{1:m})$
 $= \operatorname{argmax} P(y_1|x_{1:m}) \cdot P(y_2|y_1, x_{1:m}) \cdot P(y_3|y_2, y_1, x_{1:m}) \cdots P(y_n|y_{1:n-1}, x_{1:m})$
 $= \operatorname{argmax} \prod_{t=1}^n P(y_t|\{y_1, \dots, y_{t-1}\}, x_{1:m})$


신경망 기반 기계번역

- RNN 기반의 Sequence-to-Sequence 모델

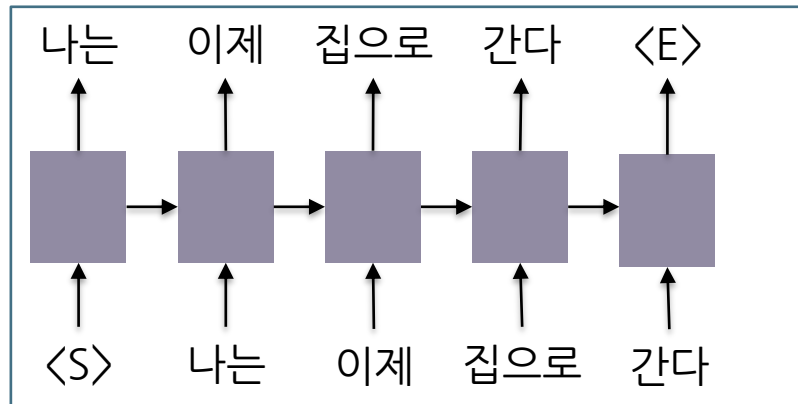
- $y_{1:n}^* = \underset{y}{\operatorname{argmax}} \prod_{t=1}^n P(y_t | \underbrace{\{y_1, \dots, y_{t-1}\}}_{\text{Decoder}}, \underbrace{x_{1:m}}_{\text{Encoder}})$

↑
Decoder ↑
Encoder

Encoder




Decoder



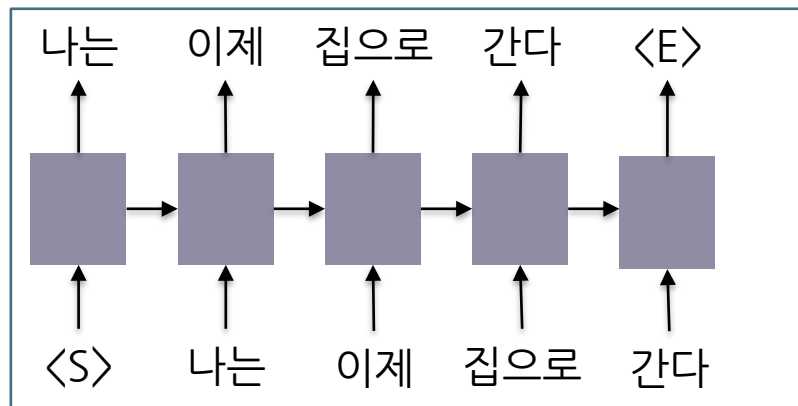
신경망 기반 기계번역

- RNN 기반의 Sequence-to-Sequence 모델
 - Encoder로 부터 입력열에 대한 **고정 길이 벡터** 생성 방법 ?

Encoder



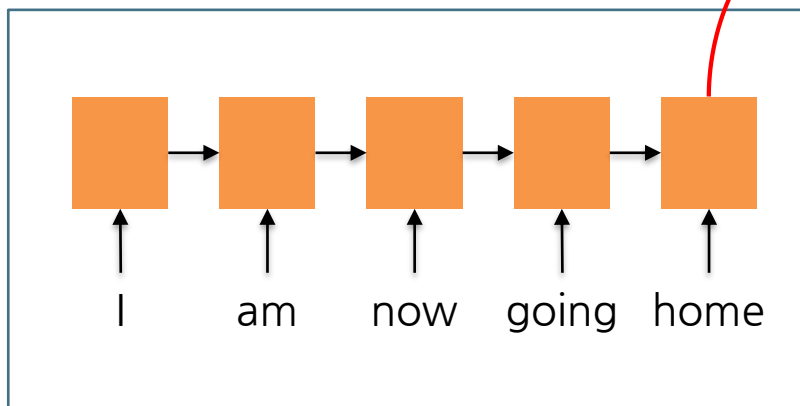
Decoder



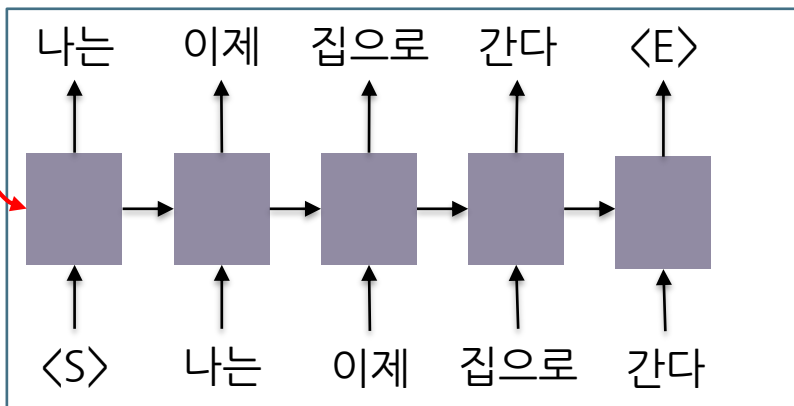
신경망 기반 기계번역

- RNN 기반의 Sequence-to-Sequence 모델
 - Encoder로 부터 입력열에 대한 **고정 길이 벡터** 생성 방법 ?
 - 가장 쉬운 방법
 - Encoder의 마지막 Hidden으로 Decoder의 Hidden을 초기화
→ $h_t^{Enc} = f(x_1, x_2, \dots, x_n)$

Encoder




Decoder



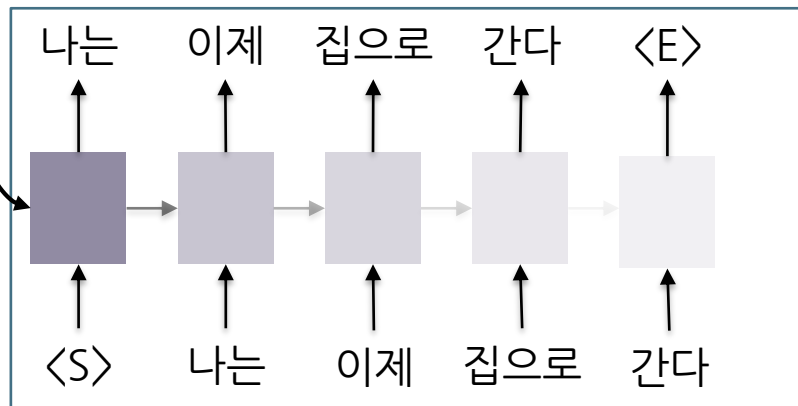
신경망 기반 기계번역

- 장기 의존성 학습 어려움: Long-term dependency
 - Decoder의 **time-step이 증가할 수록** Encoder의 정보 전달이 약해짐.
 - ➔ Encoder의 정보 활용이 부족.

Encoder



Decoder



신경망 기계번역

- Attention

- Concept

- y_t 를 번역(생성) 할 때 Encoder의 전체 입력열을 **중요도**에 따른 비율로 참조하는 것.

- 중요도 (가중치) 에 따라 Encoder의 전체 입력열을 압축된 **Vector**로 변환 (a.k.a. 'Context vector')

신경망 기계번역: Attention

- Concept

나는 이제 집으로 간다

I am now going home

신경망 기계번역: Attention

- Concept

나는

이제

집으로

간다



I



am



now



going



home

신경망 기계번역: Attention

- Concept

나는

이제

집으로

간다



I



am



now



going



home

신경망 기계번역: Attention

- Concept

나는

이제

집으로

간다



I



am



now




going



home

신경망 기계번역: Attention

- Concept



신경망 기계번역: Attention


- Concept

나는 이제 집으로 간다



$$0.05 \times \boxed{h_1} + 0.1 \times \boxed{h_2} + 0.25 \times \boxed{h_3} + 0.4 \times \boxed{h_4} + 0.2 \times \boxed{h_5} = \boxed{C_{\text{vector}}}$$

신경망 기계번역: Attention



Bahdanau, Dzmitry, Kyunghyun Cho, and Yoshua Bengio.

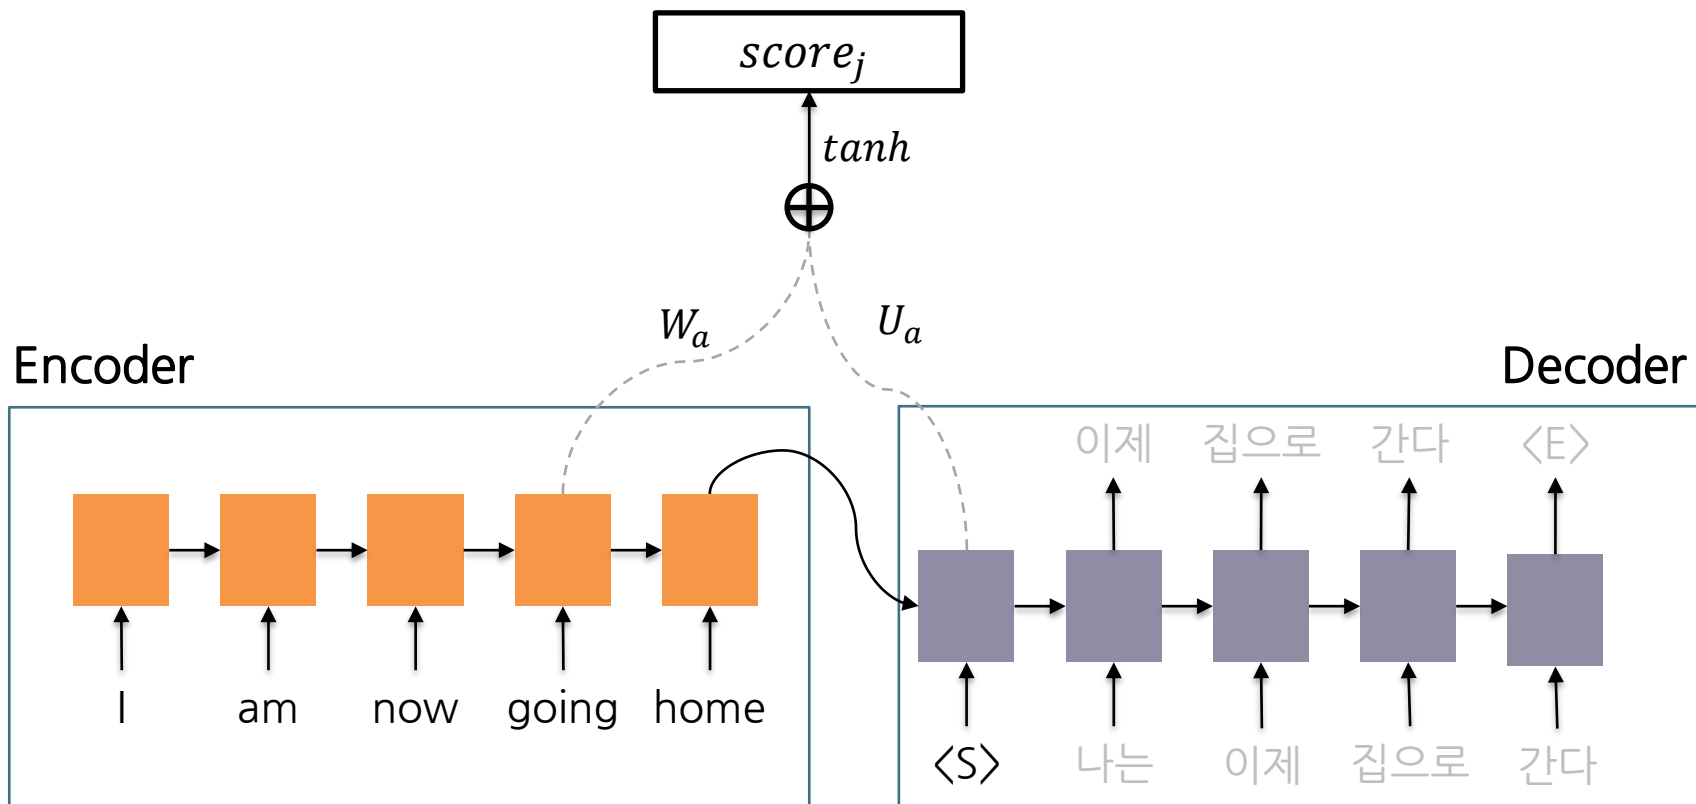
"Neural machine translation by jointly learning to align and translate."

Figure 3: Four sample alignments found by RNNsearch-50. The x-axis and y-axis of each plot correspond to the words in the source sentence (English) and the generated translation (French), respectively. Each pixel shows the weight α_{ij} of the annotation of the j -th source word for the i -th target word (see Eq. (6)), in grayscale (0: black, 1: white). (a) an arbitrary sentence. (b–d) three randomly selected samples among the sentences without any unknown words and of length between 10 and 20 words from the test set.

신경망 기계번역: Attention

- In practice: MLP approach

- $\text{score}(h_i^{Enc}, h_t^{Dec}) = v_a^T \tanh(W_a h_j^{Enc} + U_a h_t^{Dec}) \rightarrow \text{scalar}$



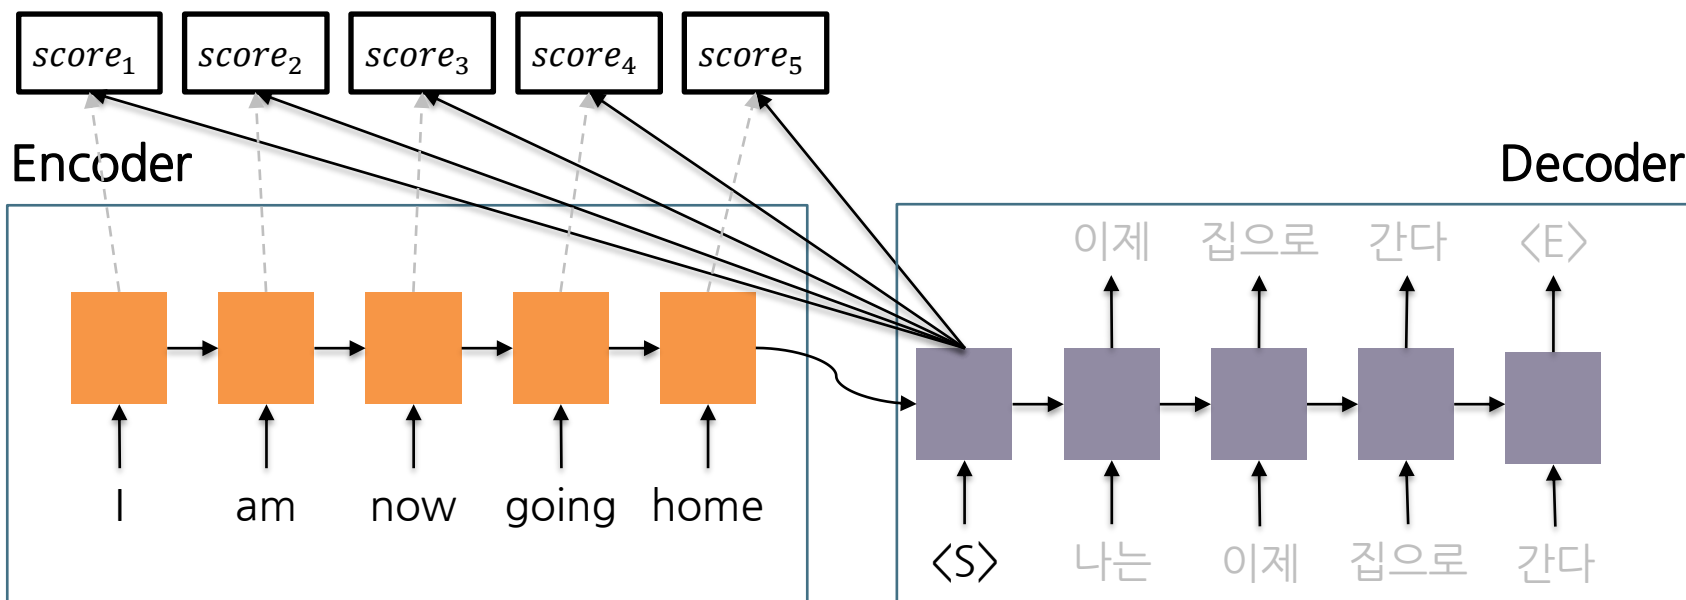
신경망 기계번역: Attention

- In practice: MLP approach

- $\text{score}(h_j^{Enc}, h_t^{Dec}) = v_a^T \tanh(W_a h_j^{Enc} + U_a h_t^{Dec})$

0.2 0.1 0.4 0.1 0.2

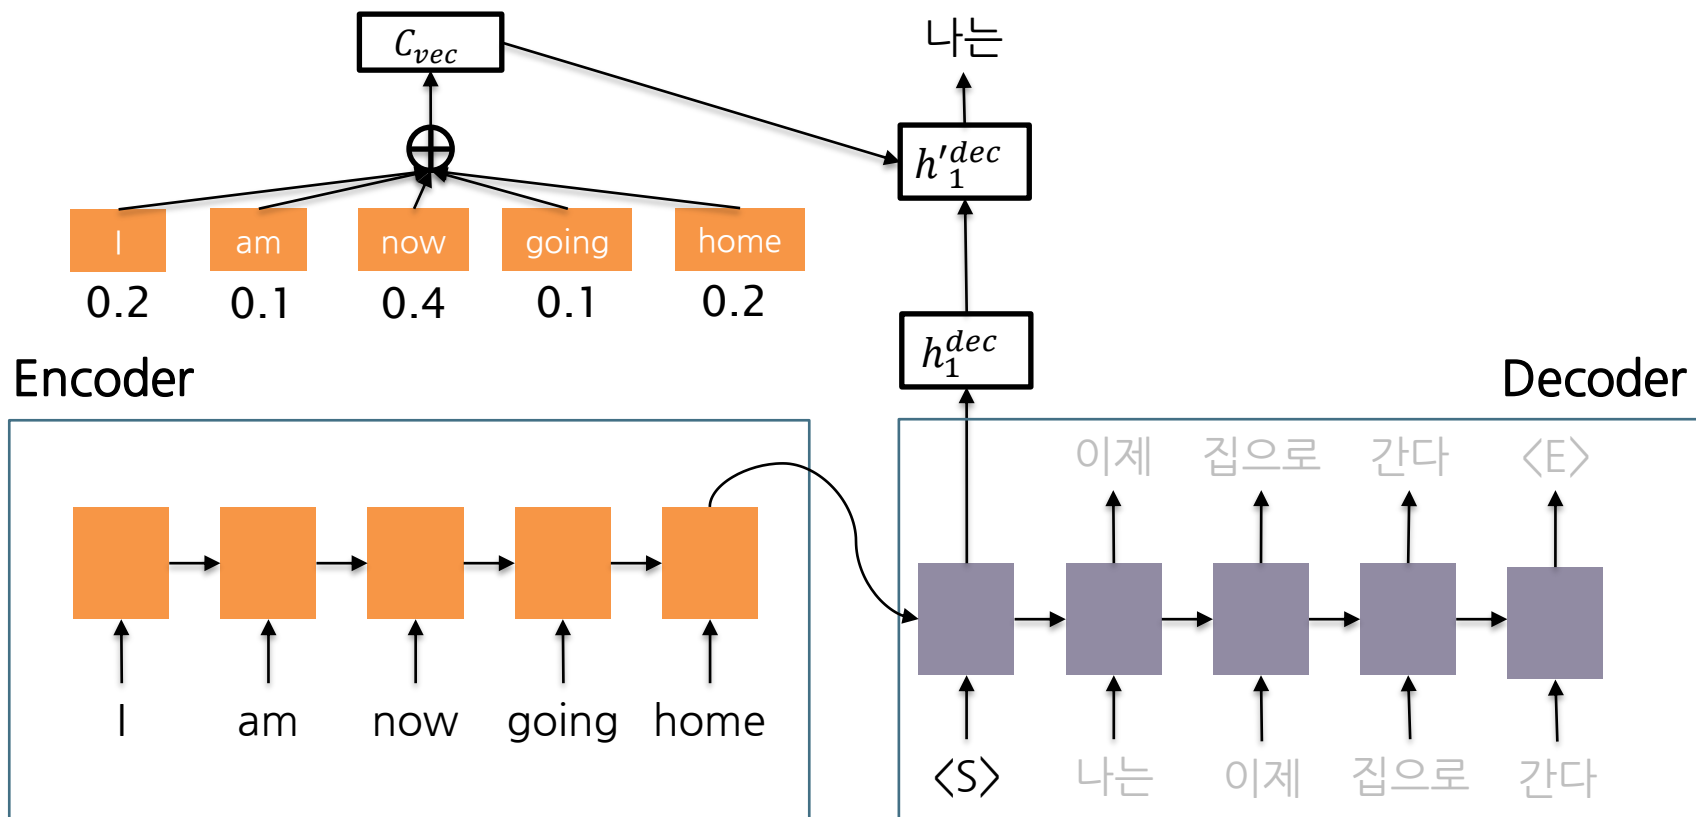
Softmax



신경망 기계번역: Attention

- In practice: MLP approach

- $C_{vec} = \sum_{j=1}^{|x|} a_j \cdot h_j^{Enc}$



PRACTICE

Requirement

- `pip install torchtext`
- `pip install mosestokenizer`
- `pip install torch`